Resultados: clasificación de informalidad laboral (EPEN Puno 2024)

1. Datos

Etapa	Filas	Detalle
Base completa	19 846	131 columnas
Solo ocupados	8 464	Informal 6 660 (78.7 %) · Formal 1 804 (21.3 %)
Variables finales (X)	8 464	36 variables
Entrenamiento / Prueba	5 924 / 2 540	70 / 30 estratificado · 78.7 % informales en ambos

Variable objetivo: 1 = informal, 0 = formal. Vacíos tras imputar con mediana: 0 en train y test.

Preprocesamiento	Detalle
Variables de fuga eliminadas	C310–C313, C317, C317A, SEGURO1, Informal_P y prefijos C361_, C362_, C364_, C365_
Identificadores y fechas	LLAVE_PANEL, CONGLOMERADO, SELVIV, HOGAR, MUESTRA, C201, C300n, NROINF, FAC300_ANUAL · ANIO, MES, C301_*
Otras eliminaciones	CCDD, OCUP300, RESIDENT · constantes · columnas con más de 50 % de vacíos
Vacíos restantes	C335 (10.0 %) y C366_1 (8.4 %), imputados con la mediana del entrenamiento
Códigos reducidos	C308_COD → OCUP_GRUPO (1 dígito) · C309_COD → RAMA_DIV (2 dígitos)
Nominales (texto)	C203, C376, C377, OCUP_GRUPO, RAMA_DIV

Variables finales (36): ESTRATO, AREA, C203, C204, C207, C208, C303, C318_1 a C318_7, C318_T, whoraT, C330, C333, P209H, C335, C359, C366, C366_1, C375_1 a C375_6, C376, C377, INGTOT, INGTOTP, ingtrabw, OCUP_GRUPO, RAMA_DIV.

Interpretación: *Las clases están desbalanceadas (78.7 % informales): un modelo que siempre responde "informal" ya alcanza 0.787 de Accuracy, por eso se evalúa con Balanced Accuracy y ROC AUC.*

2. LazyPredict (27 modelos)

Se muestran los 10 con mayor Balanced Accuracy. Los 5 primeros se usan en las secciones 3 a 5. El modelo base (DummyClassifier) obtiene Accuracy 0.787, Balanced Acc. 0.500 y ROC AUC 0.500; el más bajo es QuadraticDiscriminantAnalysis (Balanced Acc. 0.577).

Modelo	Accuracy	Balanced Acc.	ROC AUC	F1	Tiempo entren. (s)
LGBMClassifier	0.915	0.848	0.955	0.913	0.414
XGBClassifier	0.915	0.848	0.953	0.913	0.506
BaggingClassifier	0.913	0.848	0.920	0.911	0.911
CalibratedClassifierCV	0.920	0.847	0.954	0.917	0.929
LinearSVC	0.921	0.845	0.954	0.918	0.372
RandomForestClassifier	0.917	0.842	0.951	0.914	1.711
ExtraTreesClassifier	0.913	0.837	0.950	0.910	1.038
AdaBoostClassifier	0.902	0.833	0.935	0.900	1.050
LogisticRegression	0.903	0.825	0.942	0.900	0.314
KNeighborsClassifier	0.903	0.825	0.901	0.900	0.395

Interpretación: *Los 5 primeros modelos están casi empatados (Balanced Acc. 0.845–0.848) y todos superan claramente al modelo base (0.500). La elección se decide por los recursos que consumen.*

3. Espacio, memoria y tiempo de predicción

Espacio: tamaño del modelo entrenado. Memoria: pico de RAM extra durante fit, con los datos originales (n) y con 30 veces más filas (n×30). Tiempo: predicción sobre el conjunto de prueba.

Modelo	Espacio (KB)	Memoria fit n (MB)	Memoria fit n×30 (MB)	Predicción (s)
LGBMClassifier	347.8	0.0	154.1	0.0488
XGBClassifier	253.4	0.4	168.1	0.0290
BaggingClassifier	560.2	0.0	177.6	0.0339
CalibratedClassifierCV	10.3	0.0	243.2	0.0868
LinearSVC	6.4	0.0	192.1	0.0359

Interpretación: *Los modelos lineales (LinearSVC 6.4 KB, CalibratedClassifierCV 10.3 KB) ocupan muy poco espacio; Bagging es el más grande (560.2 KB). Con n×30, LGBM usa la menor memoria (154.1 MB) y CalibratedClassifierCV la mayor (243.2 MB). Todos predicen las 2 540 filas de prueba en menos de 0.09 s.*

4. Complejidad computacional

Orden teórico aproximado (n = filas, d = variables, T = árboles, B = estimadores, k = pliegues internos). Medido (sección 3): el espacio va de 6.4 KB (LinearSVC) a 560.2 KB (Bagging), y con n×30 la memoria pico de entrenamiento va de 154.1 MB (LGBM) a 243.2 MB (CalibratedClassifierCV).

Modelo	Entrenamiento	Predicción (por muestra)	Espacio del modelo
LGBMClassifier	O(T·n·d) con histogramas	O(T·profundidad)	O(T·hojas)
XGBClassifier	O(T·n·d) con histogramas	O(T·profundidad)	O(T·hojas)
BaggingClassifier	O(B·n·d·log n)	O(B·profundidad)	O(B·nodos), crece con n
CalibratedClassifierCV	O(k·n·d)	O(k·d)	O(k·d)
LinearSVC	O(n·d) por iteración	O(d)	O(d)

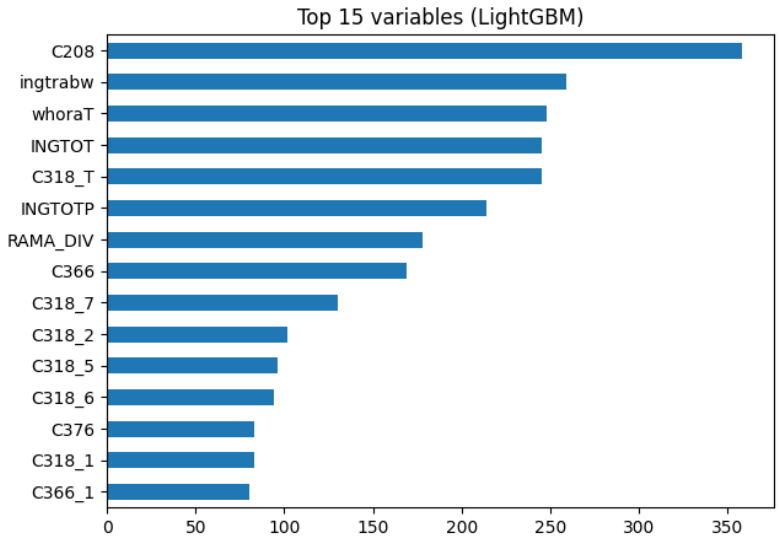
Interpretación: *Los modelos basados en árboles escalan con el número de árboles (T o B) y los lineales solo con las variables (d), lo que coincide con el espacio medido: pequeño en los lineales y mayor en Bagging.*

5. Validación cruzada (5 pliegues)

Modelo	Balanced Acc.	ROC AUC	F1
LGBMClassifier	0.853 ± 0.009	0.950 ± 0.002	0.915 ± 0.005
XGBClassifier	0.851 ± 0.011	0.948 ± 0.003	0.912 ± 0.007
BaggingClassifier	0.848 ± 0.008	0.919 ± 0.005	0.902 ± 0.006
CalibratedClassifierCV	0.843 ± 0.008	0.947 ± 0.003	0.913 ± 0.003
LinearSVC	0.838 ± 0.012	0.947 ± 0.003	0.913 ± 0.004

Interpretación: *LGBMClassifier mantiene el mejor Balanced Acc. (0.853) con baja variación entre pliegues (± 0.009), en línea con el resultado en el conjunto de prueba.*

6. Importancia de variables (LightGBM)

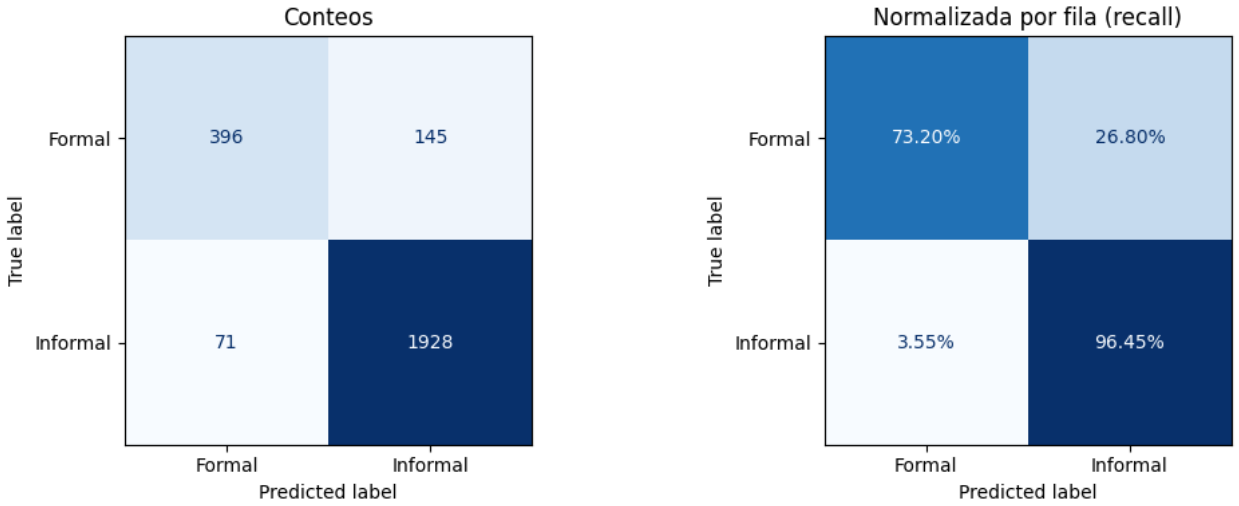


Top 15 variables por importancia. Las cinco primeras: C208, ingtrabw, whoraT, INGTOT y C318_T.

Interpretación: *Las variables más influyentes son C208 y las de ingreso y horas trabajadas (ingtrabw, INGTOT, whoraT).*

7. Matriz de confusión y error (LGBMClassifier, prueba)

Clase	Precisión	Recall	F1	Soporte
Formal (0)	0.848	0.732	0.786	541
Informal (1)	0.930	0.964	0.947	1 999
Exactitud global			0.915	2 540
Promedio macro	0.889	0.848	0.866	2 540
Promedio ponderado	0.913	0.915	0.913	2 540



TN = 396 · FP = 145 (26.8 % de los formales) · FN = 71 (3.6 % de los informales) · TP = 1 928.

Tasa de error por	Valores
AREA	1: 9.9 % (n=2 138) · 2: 1.0 % (n=402)
OCUP_GRUPO (mayores)	3: 27.3 % · 4: 20.0 % · 2: 13.1 % · 5: 11.4 %
OCUP_GRUPO (menores)	7: 9.9 % · 8: 8.3 % · 9: 3.8 % · 6, 1, 0: 0.0 %
C203 (n mayor)	7: 15.4 % (n=13) · 1: 9.2 % (n=1 461) · 2: 8.1 % (n=633) · 3: 6.8 % (n=409)

Interpretación: *El modelo detecta muy bien a los informales (recall 0.964), pero clasifica peor a los formales (recall 0.732; 26.8 % marcados como informales). El error es mayor en el área 1 (9.9 % frente a 1.0 % en el área 2) y en los grupos ocupacionales 3 y 4. LGBMClassifier se elige por combinar el mayor Balanced Acc., la menor memoria con n×30 y un tiempo de entrenamiento bajo (0.414 s).*

Anexo

Repositorio del proyecto (GitHub): https://github.com/Shanellilaquita/ciencia_datos_2daU.git